

# Comparación: Dice Loss vs Binary Crossentropy

## 1. Binary Crossentropy (BCE)

La Binary Crossentropy (BCE) mide la diferencia entre la distribución de probabilidades predicha y la distribución verdadera (ground truth) para un problema de clasificación binaria. La fórmula matemática es:

$$\text{BCE} = -\frac{1}{N} \sum_{i=1}^N [g_i \log(p_i) + (1 - g_i) \log(1 - p_i)]$$

donde:

- $p_i$  es la probabilidad predicha para el ejemplo  $i$ ,
- $g_i$  es la etiqueta verdadera (0 o 1) para el ejemplo  $i$ ,
- $N$  es el número total de ejemplos.

Esta función mide qué tan bien predice el modelo la etiqueta verdadera, penalizando más las predicciones incorrectas en las que el modelo está muy seguro. Es común en problemas de clasificación.

## 2. Dice Loss

La Dice Loss es común en tareas de segmentación, ya que evalúa la superposición entre la predicción y la etiqueta verdadera. La fórmula es:

$$\text{Dice Loss} = 1 - \frac{2 \sum_{i=1}^N p_i g_i}{\sum_{i=1}^N p_i + \sum_{i=1}^N g_i}$$

donde:

- $p_i$  es la predicción del modelo para el píxel  $i$ ,
- $g_i$  es la etiqueta verdadera para el píxel  $i$ ,
- $N$  es el número total de píxeles.

Esta fórmula mide qué tan bien se superponen las áreas predichas con las áreas verdaderas, lo que es esencial en problemas de segmentación de imágenes.

### 3. Comparación

#### 3.1 Sensibilidad al Desbalance de Clases

La **Binary Crossentropy** es sensible al desbalance de clases. Si una clase es más frecuente, la BCE tenderá a centrarse en predecir correctamente esa clase mayoritaria. En cambio, la **Dice Loss** es menos sensible al desbalance, ya que se enfoca en la superposición de áreas.

#### 3.2 Propósito

- La **Binary Crossentropy** se usa principalmente para problemas de clasificación binaria, donde se desea minimizar la diferencia entre la probabilidad predicha y la verdadera. - La **Dice Loss** es más común en problemas de segmentación, donde la superposición entre las áreas predichas y las verdaderas es importante.

#### 3.3 Penalización de Errores

En **Binary Crossentropy**, si el modelo está seguro pero se equivoca (predicción cercana a 1 cuando la verdad es 0), se penaliza fuertemente. En **Dice Loss**, la penalización se centra en la falta de superposición de áreas, lo que es más adecuado para la segmentación.